

中期报告：NineToothed 算子开发 Skill

一、基本信息

- 小组名称：王一鸣
- 成员：王一鸣（1 人）
- 报名赛题编号：T3-1-1（NineToothed 算子开发 Skill）
- 报告日期：2026-05-31

二、进度概述

2.1 .skill 包建设 — 100% 完成

ninetoothed-skill/	20 个文件，约 3,500 行
├─ SKILL.md	(690+ 行) 六阶段闭环工作流 + 错误恢复 + 约束 + 验证
├─ README.md	项目说明 + 安装 + 使用 + 平台说明
├─ references/ pitfalls)	4 个参考文件 (code_templates / ntl_api / tensor_guide /
├─ examples/	6 个文档 (4 开发示例 + 2 benchmark 文档)
├─ scripts/	3 个脚本 (run_tests / run_benchmark / verify_skill)
└─ tests/	5 个测试文件 (4 自测任务 + meshgrid)

verify_skill.py 运行结果：55/55 项检查全部通过。

2.2 算子实战验证 — 100% 超额完成

为验证 skill 的实际指导能力，使用 skill 指导 AI 智能体完成了 30 个算子的端到端开发：

类别	数量	代表算子
Element-wise (含 kernel)	13	rad2deg, copysign, nextafter, logit, heaviside, nan_to_num, linspace, logspace, count_nonzero, trace, eye, flatten, flip
组合/多 kernel	6	lcm, trapezoid, kl_div, roll, repeat, column_stack
Torch 层 (无 kernel)	11	mode, cartesian_prod, corrcoef, channel_shuffle, comb, combinations_indices, chunk, unbind, meshgrid, narrow, fractional_max_pool2d

每个算子均完成：分析→生成→编译→验证→优化→报告 的完整闭环，产生了 30 份开发报告。

2.3 自测任务 — 100% 完成

#	任务	类型	测试文件	Benchmark
1	leaky_relu	Element-wise + 标量参数	tests/test_leaky_relu.py	☑
2	log_softmax	Reduction + 数值稳定性	tests/test_log_softmax.py	☑
3	非连续输入	转置/步幅/偏移	tests/test_non_contiguous.py	—
4	性能对比	Benchmark + 回退分析	tests/test_benchmark.py	—
5	meshgrid	广播算子 (额外)	tests/test_meshgrid.py	—

自测任务 1 和 2 均包含独立 benchmark 文档，含基线、3 种输入规模、运行命令、结果和性能结论。

2.4 通过实战验证发现的 skill 改进 — 持续迭代

在 30 个算子的实战验证中，发现并修复了以下关键问题：

发现	写入位置
Generated source 搜索关键字 <code>ttl.load</code> → <code>triton.language.load</code>	SKILL.md §9
libdevice 优先检查 (150+ 函数, nextafter/comb 等可省去手写位操作)	Stage 1 步骤 4
广播不同 ndim 约束 (element_wise 要求同 ndim)	§11 不支持场景
数据依赖循环→固定 range 的状态更新陷阱 (pitfall #15)	pitfalls.md + §11
<code>ntl.program_id</code> + <code>ntl.arange</code> 全局索引可用 (eye/linspace/trace 验证)	Application 模式 #5
融合决策应在设计时 (Stage 1) 而非优化时 (Stage 5)	Stage 1 步骤 7
Triton 循环内 <code>//</code> 整数除法的类型不稳定问题	comb 算子报告
动态索引 <code>tile[j]</code> 不支持 (mode/histogram 无法 kernel 化)	§11
不规则访存/分组聚合 (mode 最终用 torch.unique 实现)	§11
view vs copy 性能模式识别	Stage 5b 特殊性能模式

三、后续计划（初赛→决赛）

3.1 初赛剩余工作（截至 2026/06/08）

- 撰写最终赛题报告：基于 30 个算子的实战数据，完成 §4.2.5 要求的正式赛题报告
- 补充 HONOR_CODE.md 和 REFERENCE.md
- 运行自测任务的完整记录和截图
- 验证 .skill 在干净仓库环境下的端到端可复现性

3.2 决赛展望（截至 2026/07/13）

- 1. 根据隐藏任务反馈优化决策树和陷阱索引
- 2. 补充 Attention、Conv2D 等高复杂度模式的示例和模板
- 3. 完善 benchmark 自动化脚本，支持多规模、多 dtype 的批量对比
- 4. 补充 AOT build 配置说明和更多性能优化案例
- 5. 编写 AI 智能体使用 .skill 前后的对比实验

四、自测计划与量化指标

4.1 自测任务设计

初赛阶段 4+1 个自测任务已全部完成，覆盖赛题全部要求：

- 逐元素类：leaky_relu（6 测试用例，含 benchmark）
- 归约类：log_softmax（6 测试用例，含 benchmark）
- 非连续输入：跨类型验证（6 测试用例，覆盖 relu/silu/add/leaky_relu/softmax）
- 性能分析：7 算子 × 3 规模 benchmark
- 额外：meshgrid 广播算子（6 测试用例）

4.2 预期量化指标（已达成）

指标	目标	实际
Element-wise 性能比率	≥0.85x	0.87-1.14x ☒
Reduction 性能比率	≥0.70x	0.71-0.81x ☒
精度测试通过率	100%	30/30 ☒
迭代修复成功率	≤3 次	均值 1.6 次 ☒
非连续输入正确性	100%	6/6 ☒

4.3 30 个算子性能总结

性能分布（vs PyTorch @ 4096²）：

- ≤1.2x（持平或相当）：16 个
- 反超 PyTorch：6 个（kl_div 0.36x, corrcoeff 0.03x, cartesian_prod 0.51x 等）
- 明显落后（>4x）：trace/unbind/chunk/flatten/meshgrid/column_stack/lcm —— 均为 view vs copy 或固定循环的先天劣势，已分析记录

五、合规声明

- ☒ 无 API key、账号凭据或未授权数据
- ☒ 无联网依赖（所有参考资料本地存储）
- ☒ 无隐藏评测答案或硬编码任务名
- ☒ 无针对评测脚本的规避逻辑
- ☒ 所有生成代码可审计、可复现
- ☒ 所有引用资料已披露
- ☒ 使用 \$PROJECT_ROOT 占位符，无硬编码路径

