

自测计划：NineToothed 算子开发 Skill

一、基本信息

- 小组名称：王一鸣
- 赛题编号：T3-1-1
- 日期：2026-05-31

二、自测任务总览

#	任务	类型	算子	测试文件	Benchmark
1	逐元素算子	Element-wise + 标量	leaky_relu	tests/test_leaky_relu.py	☑
2	归约算子	Reduction + 数值稳定性	log_softmax	tests/test_log_softmax.py	☑
3	非连续输入	转置/步幅/偏移	跨类型验证	tests/test_non_contiguous.py	—
4	性能分析	Benchmark + 回退	7 算子对比	tests/test_benchmark.py	—
5	广播算子	1D→2D 广播	meshgrid	tests/test_meshgrid.py	—

三、各任务详细说明

自测任务 1：Element-wise 算子 — leaky_relu

- 算子公式： $f(x) = x \text{ if } x \geq 0 \text{ else } \text{negative_slope} * x$
- 输入任务： `leaky_relu(x, negative_slope=0.01)`，带可配置标量参数
- 测试覆盖： float32/float16、3 种规模 (256/1024/4096)、多种 slope 值 (0.01-2.0)、边界 (全正/全负/全零)、3D 输入
- 迭代历史： 3 次迭代 (闭包 NameError → fp64 IncompatibleTypeError → constexpr 成功)
- 性能数据： 4096×4096 float32: ntops 0.25ms vs PyTorch 0.23ms (0.92x)

自测任务 2：Reduction 算子 — log_softmax

- **算子公式**: `log(softmax(x, dim))`, 需要数值稳定实现
- **输入任务**: online max + log-sum-exp 算法, float16 中间计算提升到 float32
- **测试覆盖**: float32/float16、dim=0/dim=-1、3D 输入、极端值 (-10000~10000)、非整除 block_size
- **迭代历史**: 1 次通过
- **性能数据**: 4096×1024 float32: ntops 0.36ms vs PyTorch 0.29ms (0.81x)

自测任务 3：非连续输入场景

- **测试覆盖**: 转置张量 (`.t()`)、步幅切片 (`[::2]`)、覆盖 5 种算子
- **验证算子**: relu, silu, add, leaky_relu (element-wise)、softmax (reduction)
- **验证结论**: NineToothed 自动处理 stride, 无需 `.contiguous()`

自测任务 4：性能对比与回退分析

- **测试算子**: 7 个 (relu, silu, add, leaky_relu, softmax, log_softmax, mm)
- **规模**: 3 种 (256² / 1024² / 4096²)
- **计时方式**: CUDA events, 10 warmup + 100 repeat
- **回退分析**: 当性能比率 >1.5x 时, 按 6 步流程诊断根因
- **性能结论**: Element-wise 0.87-0.93x, Reduction 0.71-0.81x, Matmul 0.29x (Windows Triton 限制)

自测任务 5：广播算子 — meshgrid (额外)

- **测试覆盖**: float32/float16、不等长输入、非整除 block_size、边界情况
- **Arrangement 模式**: 自定义 tile + expand 广播

四、预期量化指标 (已达成)

指标	目标	实际达成	状态
Element-wise 性能比率	≥0.85x PyTorch	0.87-0.93x	☑
Reduction 性能比率	≥0.70x PyTorch	0.71-0.81x	☑
精度测试通过率	100%	100%	☑
迭代修复成功率 (≤3 次)	≥80%	100% (均值 1.6 次)	☑
非连续输入正确性	100%	100%	☑
Skill 自验证通过	55/55	55/55	☑

五、扩展验证 (超额完成)

为验证 skill 的泛化能力, 额外完成了 25 个算子的端到端开发和测试:

- **Element-wise**: copysign, nextafter, logit, heaviside, nan_to_num, linspace, logspace, count_nonzero, trace, eye, flatten, flip
- **组合/多 kernel**: lcm, trapezoid, kl_div, roll, repeat, column_stack

- **Torch 层**: mode, cartesian_prod, corrcoef, channel_shuffle, comb, combinations_indices, fractional_max_pool2d, chunk, narrow, unbind, deg2rad

全部 30 个算子精度测试通过，每个算子有完整的六阶段闭环报告。

六、运行方式

```
# 运行全部自测
cd $PROJECT_ROOT
python ninetoothed-skill/scripts/run_tests.py

# 运行性能基准测试
python ninetoothed-skill/scripts/run_benchmark.py

# 运行 skill 自身验证
python ninetoothed-skill/scripts/verify_skill.py

# 单独运行某个测试
cd $PROJECT_ROOT/ntops
python -m pytest tests/test_leaky_relu.py -v
```

七、后续计划

决赛阶段（截至 2026/07/13）计划补充：

1. 补充 Attention、Conv2D 等高复杂度模式的示例和模板
2. 完善 AOT build 配置说明和自动化脚本
3. 补充 AI 智能体使用 skill 前后的对比实验数据
4. 根据隐藏任务反馈优化决策树和陷阱索引
5. 编写最终赛题报告，包含完整的前后对比分析